

Υλοποίηση δέντρου απόφασης σε Python

Σας δίνετε το dataset *PlayTennis.csv*.

Αποτελεί ένα από τα πλέον γνωστά σύνολα δεδομένων, καθώς χρησιμοποιείται συχνά σε παραδείγματα μηχανικής μάθησης, ειδικά για την επίδειξη αλγορίθμων δέντρων απόφασης. Περιλαμβάνει πληροφορίες σχετικά με τις ημερήσιες καιρικές συνθήκες και την απόφαση για το αν θα παίξει κάποιος τένις.

Κάθε γραμμή αντιπροσωπεύει μια παρατήρηση (μία ημέρα) με συγκεκριμένα χαρακτηριστικά και το αποτέλεσμα (ναι ή όχι). Αποτελείται από **14 παρατηρήσεις (ημέρες)** και **4 χαρακτηριστικά** με βάση τα οποία λαμβάνεται η απόφαση για το αν θα παίξει κανείς τένις.

Τα χαρακτηριστικά του προβλήματος είναι τα εξής:

1. **Outlook** (Καιρός) με δυνατές τιμές:
 - a. Sunny
 - b. Overcast
 - c. Rain
2. **Temperature** (Θερμοκρασία) με δυνατές τιμές:
 - a. Hot
 - b. Mild
 - c. Cool
3. **Humidity** (Υγρασία) με δυνατές τιμές:
 - a. High
 - b. Normal
4. **Wind** (Άνεμος) με δυνατές τιμές:
 - a. Weak
 - b. Strong

Στον παρακάτω πίνακα εμφανίζεται αναλυτικά το περιεχόμενο του dataset.

Day	Outlook	Temperature	Humidity	Wind	Play Tennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

Η στήλη *Play Tennis* αποτελεί την **μεταβλητή-στόχο**, δηλαδή την μεταβλητή που προσπαθούμε να προβλέψουμε. Δείχνει αν παίζεται τένις υπό τις συγκεκριμένες καιρικές συνθήκες που καταγράφονται από τις άλλες στήλες.

Το πρόβλημά μας

Σκοπός: Να προβλέψουμε αν θα παίξει κάποιος τένις με βάση διάφορες καιρικές συνθήκες (Outlook, Temperature, Humidity, Wind).

Δεδομένα: Χρησιμοποιούμε τα χαρακτηριστικά του dataset (Outlook, Temperature, Humidity, Wind) για να δημιουργήσουμε ένα μοντέλο που θα μπορεί να προβλέπει την μεταβλητή-στόχο (PlayTennis).

Δημιουργία Δέντρου Απόφασης:

- Το μοντέλο δέντρου απόφασης θα εξετάσει τα χαρακτηριστικά του dataset και θα επιλέξει το χαρακτηριστικό που προσφέρει τη μεγαλύτερη διάκριση (split) για να χωρίσει τα δεδομένα σε ομάδες.
- Αυτό γίνεται αναδρομικά, δημιουργώντας «κόμβους» στο δέντρο όπου κάθε κόμβος αντιπροσωπεύει μια απόφαση βασισμένη σε ένα χαρακτηριστικό.

Εκπαίδευση:

- Το δέντρο απόφασης εκπαιδεύεται με τα δεδομένα, και η διαδικασία συνεχίζεται μέχρι να φτάσουμε σε έναν κόμβο όπου οι αποφάσεις είναι αρκετά καθαρές (δηλαδή, όλα τα δεδομένα σε αυτόν τον κόμβο έχουν την ίδια τιμή για την μεταβλητή στόχος) ή μέχρι να επιτευχθεί κάποιο κριτήριο διακοπής.

Πρόβλεψη:

- Μετά την εκπαίδευση, το δέντρο μπορεί να χρησιμοποιηθεί για να κάνει προβλέψεις σε νέα δεδομένα. Κάθε νέα παρατήρηση θα ακολουθήσει το δέντρο, και ανάλογα με τα χαρακτηριστικά της, θα οδηγηθεί σε ένα από τα φύλλα του δέντρου που θα δίνει την πρόβλεψη (Ναι ή Όχι για το αν θα παιχτεί τένις).
- Για παράδειγμα έχουμε το παρακάτω σύνολο δεδομένων πρόβλεψης που αποτελείται από 4 παρατηρήσεις.

	Outlook	Temperature	Humidity	Wind	Play Tennis
0	Sunny	Hot	High	Weak	?
1	Overcast	Mild	Normal	Strong	?
2	Rain	Cool	Normal	Weak	?
3	Rain	Mild	High	Weak	?

Αξιολόγηση:

- Η απόδοση του μοντέλου μπορεί να αξιολογηθεί χρησιμοποιώντας μετρικές όπως η ακρίβεια (accuracy), συγκρίνοντας τις προβλέψεις του μοντέλου με τις πραγματικές τιμές της μεταβλητής στόχου.
- Στο παράδειγμά μας, έστω πως οι πραγματικές προβλέψεις έχουν ως εξής:

	Outlook	Temperature	Humidity	Wind	Play Tennis
0	Sunny	Hot	High	Weak	No
1	Overcast	Mild	Normal	Strong	Yes
2	Rain	Cool	Normal	Weak	Yes
3	Rain	Mild	High	Weak	No